모두를 위한

R 데이터 분석 입문

2판

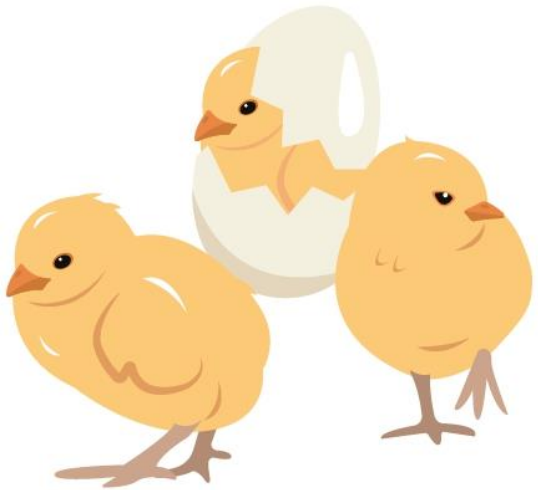

데이터 과학 data science

- 데이터에서 과학적 방법으로 정보나 지식을 추출하는 학문
- 통계학, 컴퓨터 과학 그리고 데이터가 발생하는 영역과 관련된 학문 분야의 이론과 기술을 융합적으로 사용
- 데이터 과학은 대표적인 학제 inter-disciplinary 연구 분야

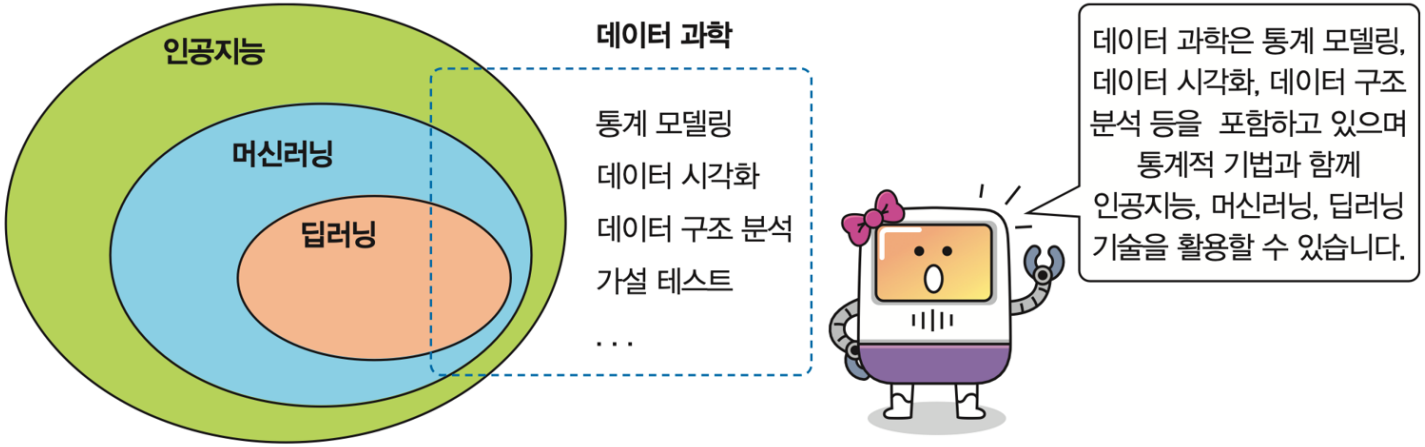

인공지능과 머신러닝, 딥러닝

인공지능이라는 용어가 나올 때마다 항상 함께 나오는 머신러닝과 딥러닝은 무엇이고 어떻게 다를까?

- **인공지능이 가장 큰 범주**
  - 인간의 지능을 구현
- **머신러닝**
  - 데이터를 기반으로 기계 스스로 학습하는 인공지능의 한 분야
- **심층신경망인 딥러닝(deep learning)**
  - 머신러닝의 여러 분야 중에서
    - **2010년 이후 현재의 인공지능 붐을 주도하고 있는 기술**
  - 퍼셉트론으로 구성된 인공신경망
    - **여러 단계의 심층 학습을 통하여 스스로 학습하는 기술**

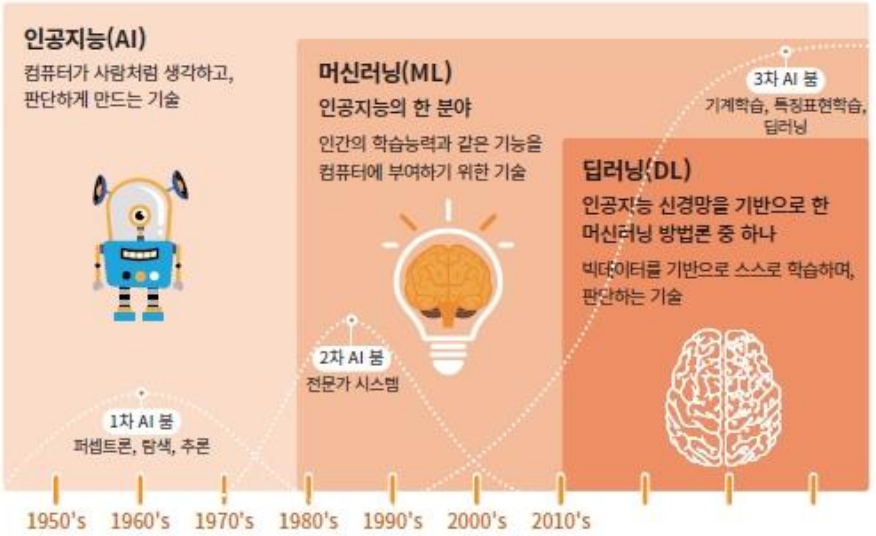

그림 6.23 ▸ 인공지능과 머신러닝, 딥러닝의 이해

머신러닝 종류 개요

- **머신러닝은 지도학습과 자율학습, 그리고 강화학습으로 분류**
  - 지도학습(supervised learning)
    - **올바른 입력과 출력의 쌍으로 구성된 정답의 훈련 데이터(labeled data)로부터 입출력 간의 함수를 학습시키는 방법**
      - - **k-최근접 이웃 (k-Nearest Neighbors)**
      - - **선형 회귀 (Linear Regression)**
      - - **로지스틱 회귀 (Logistic Regression)**
      - - **서포트 벡터 머신 (Support Vector Machines (SVM))**
      - - **결정 트리 (Decision Tree)와 랜덤 포레스트 (Random Forests)**
  - 비지도(자율)학습(unsupervised learning)
    - **정답이 없는 훈련 데이터(unlabeled data)를 사용하여 데이터 내에 숨어있는 어떤 관계를 찾아내는 방법**
      - **clustering**
  - 강화학습(reinforcement learning)
    - **잘한 행동에 대해 보상을 주고 잘못한 행동에 대해 벌을 주는 경험을 통해 지식을 학습하는 방법**
      - **딥마닝의 알파고**
      - **자동 게임분야**

Chapter 11
회귀분석

목차

Section 01

단순선형 회귀분석

1. 회귀분석 관련 용어

- 증권회사에서는 미래의 주식 시세를 예측하기 위해 많은 연구
- 주식 시세는 기업의 매출액, 원유가격, 국제정세, 정부정책 발표 등 매우 많은 요인들에 의해 영향 받음
- **독립변수(independent variable)**:주식시세에 영향을 미치는 요인들(기업의 매출액, 원유가격, 국제정세, 정부정책 발표)
- **종속변수(dependent variable)**: 독립변수의 영향에 따라 값이 결정되는 주식시세
- 독립변수와 종속변수를 다른 용어로 각각 설명변수(explanatory variable)와 반응변수(response variable)라고도 함

1. 회귀분석 관련 용어

- **예측모델(prediction model) 또는 예측모형**: 독립변수에 해당하는 자료와 종속변수에 해당하는 자료를 모아 관계를 분석하고 이를 예측에 사용할 수 있는 통계적 방법으로 정리한 것
- **회귀분석(regression analysis)**: 회귀 이론을 기초로 독립변수(설명변수)가 종속변수(반응변수)에 미치는 영향을 파악하여 예측 모델을 도출하는 통계적 방법
- 회귀분석은 여러 가지 종류가 있는데, 회귀분석에서 독립변수의 수가 하나인 경우를 **단순 회귀(simple regression)**라고 하고, 독립변수의 수가 두 개 이상인 경우를 **다중 회귀(multiple regression)**라고 함

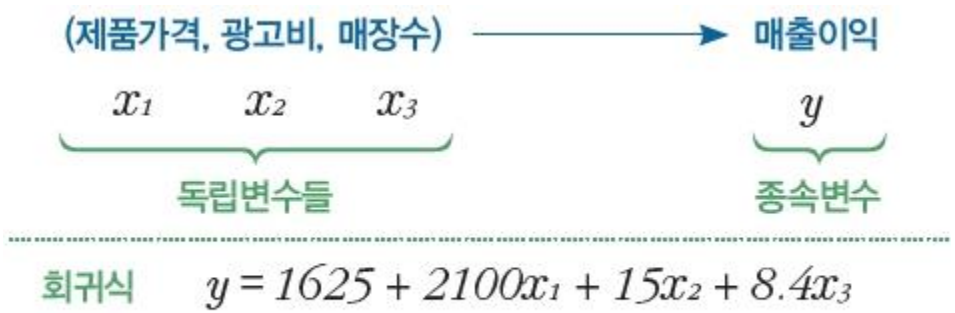

그림 11-1 독립변수, 종속변수, 회귀식

2. 단순선형 회귀분석의 목표

- **단순선형 회귀:** 독립변수(x)와 종속변수(y) 사이의 선형관계를 파악하고 이를 예측에 활용하는 통계적 방법

  ex) 기온(x) 자료를 가지고 아이스크림 판매량(y)을 예측하는 문제

- 단순선형 회귀모델 또는 단순선형 회귀식은 다음과 같이 1차식의 형태를 가짐

y = Wx + b (W, b 는 상수)

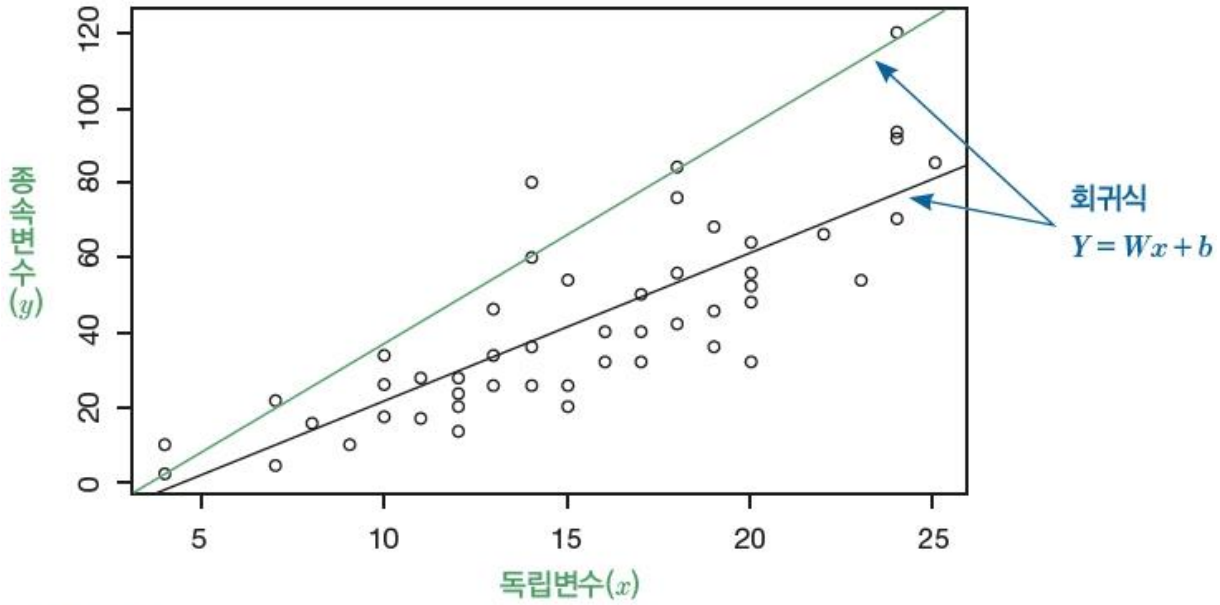

그림 11-2 산점도와 단순선형 회귀식

3. R을 이용한 단순선형 회귀분석

3.1 주행속도와 제동거리 사이의 회귀모델 구하기

- 단순선형 회귀식을 구하기 위해서는 이론적인 이해가 필요하지만, R에서 제공하는 lm() 함수를 이용하여 쉽게 회귀식을 구할 수 있음

코드 11-1

```
head(cars)
plot(dist~speed, data=cars)          # 산점도를 통해 선형 관계 확인

model <- lm(dist~speed, cars)        # 회귀모델 구하기
model

abline(model)                        # 회귀선을 산점도 위에 표시
coef(model)[1]                       # b 값 출력
coef(model)[2]                       # W 값 출력
```

1. 단순선형 회귀분석

```
> head(cars)
  speed dist
1     4    2
2     4   10
3     7    4
4     7   22
5     8   16
6     9   10
> plot(dist~speed, data=cars)              # 산점도를 통해 선형 관계 확인
>
```

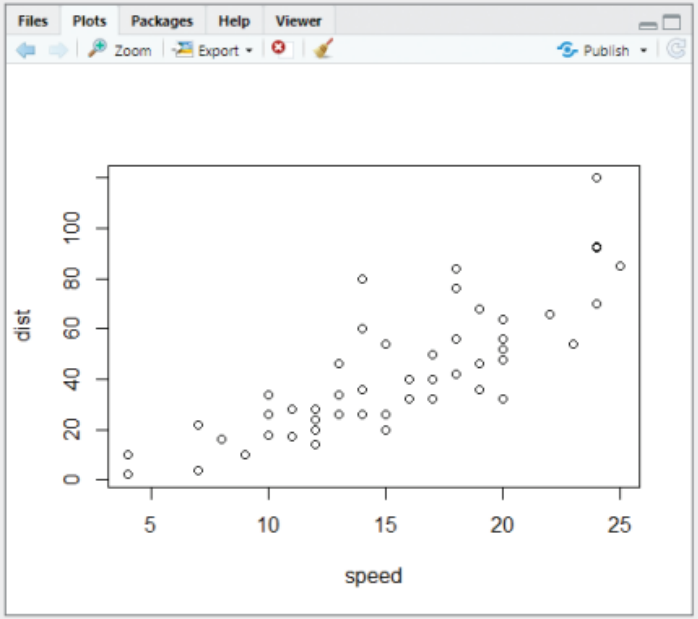

1. 단순선형 회귀분석

```
> model <- lm(dist~speed, cars)          # 회귀모델 구하기
> model
Call:
lm(formula = dist ~ speed, data = cars)

Coefficients:
(Intercept)        speed
    -17.579        3.932
```

- **dist~speed**

  회귀모델에서 독립변수와 종속변수를 지정하는 것으로, ~를 기준으로 '종속변수~독립변수'의 순서로 지정해야 한다. 여기서 순서가 바뀌면 안 된다.

- **cars**

  회귀모델을 만드는 데 사용할 데이터셋이다. 여기에서는 dist와 speed가 cars의 열이어야 한다.

1. 단순선형 회귀분석

```
> abline(model)                    # 회귀선을 산점도 위에 표시
```

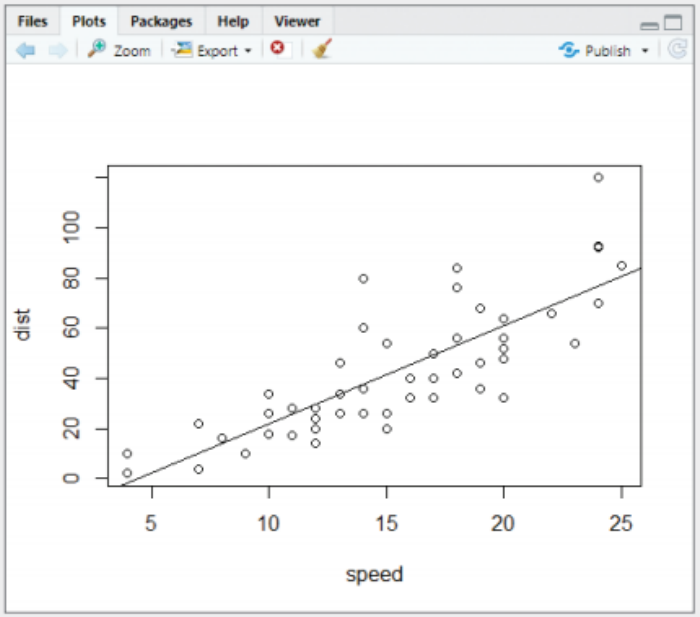


```
> coef(model)[1]                   # b 값 출력
(Intercept)
  -17.57909
> coef(model)[2]                   # W 값 출력
   speed
3.932409
```

3.2 주행속도에 따른 제동거리 구하기

코드 11-2

```
b <- coef(model)[1]
W <- coef(model)[2]

speed <- 30                    # 주행속도
dist <- W*speed + b
dist                           # 제동거리

speed <- 35                    # 주행속도
dist <- W*speed + b
dist                           # 제동거리

speed <- 40                    # 주행속도
dist <- W*speed + b
dist                           # 제동거리
```

1. 단순선형 회귀분석

```
> b <- coef(model)[1]
> W <- coef(model)[2]
> speed <- 30                                  # 주행속도
> dist <- W*speed + b
> dist                                         # 제동거리
   speed
100.3932
> speed <- 35                                  # 주행속도
> dist <- W*speed + b
> dist                                         # 제동거리
   speed
120.0552
> speed <- 40                                  # 주행속도
> dist <- W*speed + b
> dist                                         # 제동거리
   speed
139.7173
```

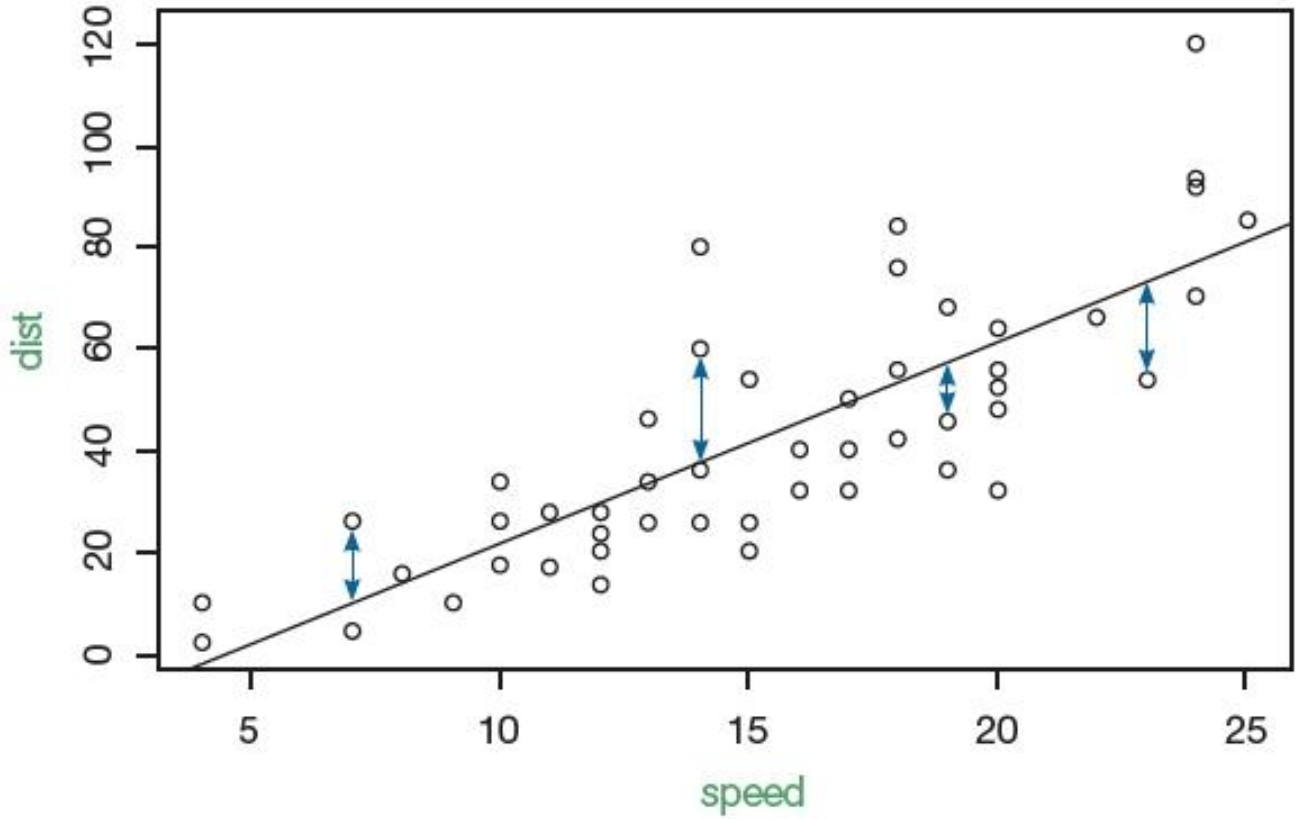

그림 11-3 회귀모델에 의한 예측값과 실제값의 차이

3.3 예상 제동거리, 실제 제동거리, 오차 구하기

- cars 데이터셋의 주행속도(speed) 데이터를 앞에서 구한 회귀식에 대입

코드 11-3

```
speed <- cars[,1]                                  # 주행속도
pred <- W * speed + b
pred                                               # 예상 제동거리

compare <- data.frame(pred, cars[,2], pred-cars[,2])
colnames(compare) <- c('예상','실제','오차')
head(compare)
```

```
> speed <- cars[,1]                                # 주행속도
> pred <- W * speed + b
```

1. 단순선형 회귀분석

```
> pred                                          # 예상 제동거리
 [1] -1.849460 -1.849460  9.947766  9.947766 13.880175
 [6] 17.812584 21.744993 21.744993 21.744993 25.677401
[11] 25.677401 29.609810 29.609810 29.609810 29.609810
[16] 33.542219 33.542219 33.542219 33.542219 37.474628
[21] 37.474628 37.474628 37.474628 41.407036 41.407036
[26] 41.407036 45.339445 45.339445 49.271854 49.271854
[31] 49.271854 53.204263 53.204263 53.204263 53.204263
[36] 57.136672 57.136672 57.136672 61.069080 61.069080
[41] 61.069080 61.069080 61.069080 68.933898 72.866307
[46] 76.798715 76.798715 76.798715 76.798715 80.731124
>
> compare <- data.frame(pred, cars[,2], pred-cars[,2])
> colnames(compare) <- c('예상','실제','오차')
> head(compare)
       예상   실제       오차
1 -1.849460     2  -3.849460
2 -1.849460    10 -11.849460
3  9.947766     4   5.947766
4  9.947766    22 -12.052234
5 13.880175    16  -2.119825
6 17.812584    10   7.812584
```

Section 02

다중선형 회귀분석

1. 다중선형 회귀모델 만들기

- 단순선형 회귀가 하나의 독립변수를 다룬다면 다중선형 회귀는 여러 개의 독립변수를 다룸
  - ex)키와 몸무게를 가지고 혈당 수치를 예측하는 문제

키(x1), 몸무게(x2): 독립변수

혈당수치(y): 종속변수

- 다중 회귀모델 (다중 회귀식)의 일반적인 형태

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \cdots\cdots + \beta_n x_n$$

- R 에서는 다중 회귀모델도 lm() 함수로 구함

코드 11-4

```
library(car)
head(Prestige)
newdata <- Prestige[,c(1:4)]                # 회귀식 작성을 위한 데이터 준비
plot(newdata, pch=16, col="blue",           # 산점도를 통해 변수 간 관계 확인

     main="Matrix Scatterplot")
mod1 <- lm(income ~ education + prestige + # 회귀식 도출
     women, data=newdata)
summary(mod1)
```

```
> library(car)
> head(Prestige)
                    education income women prestige census type
gov.administrators      13.11  12351 11.16     68.8   1113 prof
general.managers        12.26  25879  4.02     69.1   1130 prof
accountants             12.77   9271 15.70     63.4   1171 prof
purchasing.officers     11.42   8865  9.11     56.8   1175 prof
chemists                14.62   8403 11.68     73.5   2111 prof
physicists              15.64  11030  5.13     77.6   2113 prof
```

2. 다중선형 회귀분석

```
> newdata <- Prestige[,c(1:4)]          # 회귀식 작성을 위한 데이터 준비
> plot(newdata, pch=16, col="blue",     # 산점도를 통해 변수 간 관계 확인
+      main="Matrix Scatterplot")
```

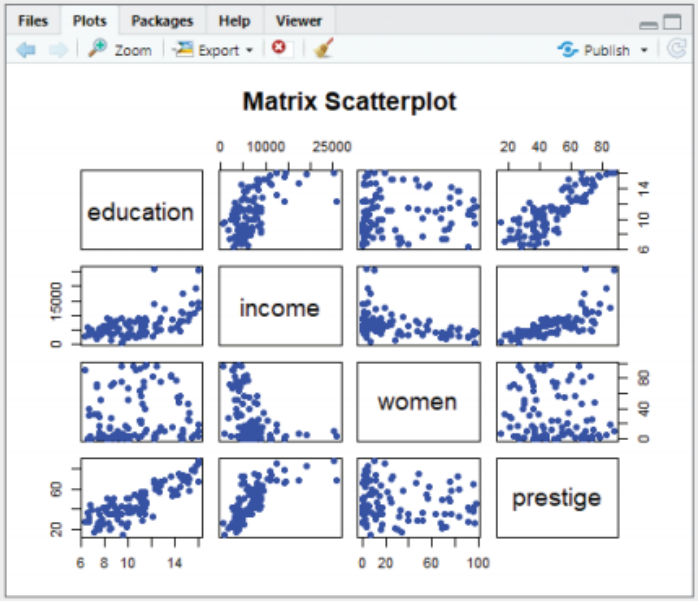

2. 다중선형 회귀분석

```
> mod1 <- lm(income ~ education + prestige +        # 회귀식 도출
+             women, data=newdata)
> summary(mod1)

Call:
lm(formula = income ~ education + prestige + women, data = newdata)

Residuals:
    Min      1Q  Median      3Q     Max
-7715.3  -929.7  -231.2   689.7 14391.8

Coefficients:
            EstimateStd. Error t value Pr(>|t|)
(Intercept) -253.850   1086.157  -0.234    0.816
education    177.199    187.632   0.944    0.347
prestige     141.435     29.910   4.729 7.58e-06  ***
women        -50.896      8.556  -5.948 4.19e-08  ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

2. 다중선형 회귀분석

```
Residual standard error: 2575 on 98 degrees of freedom
Multiple R-squared:  0.6432,Adjusted R-squared:  0.6323
F-statistic: 58.89 on 3 and 98 DF,  p-value: < 2.2e-16
```

- `income ~ education + prestige + women`

  회귀모델에서 무엇이 독립변수이고 무엇이 종속변수인지 지정하는 것으로, ~ 앞에 있는 것이 종속변수, ~ 뒤쪽에 있는 것이 독립변수이다. 독립변수가 여러 개이면 +로 연결한다.

- `data=newdata`

  회귀모델 도출에 사용할 데이터셋을 지정한다. 변수명 income, education, prestige, women은 newdata에 속한 열의 이름이다.

2. 다중선형 회귀분석

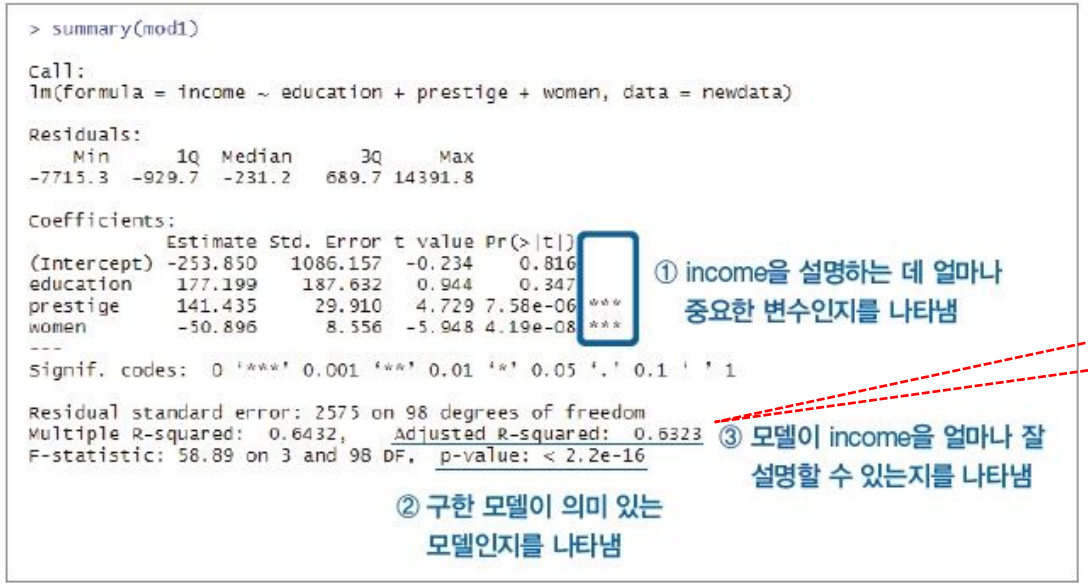

그림 11-4 회귀모델에 대한 설명 내용

- ①에 있는 *는 해당 변수가 종속변수를 설명하는 데 얼마나 중요한 변수인가를 나타냄. *가 많을수록 통계적으로 중요하다는 의미
- ②에 있는 p-value(유의수준) 값은 구한 회귀모델이 의미 있는 모델인지(신뢰할 수 있는 모델인지)를 나타내는 것으로, 이 값이 작을수록 의미 있는 모델인 것을 나타냄
- ③에 있는 Adjusted R-squared 값은 모델의 설명력을 나타내며 0~1 사이의 값을 갖음

2. 다중선형 회귀분석

- 교육 수준은 수입과 양(+)의 관계를 보이지만, 통계적으로 유의하지 않음.
- 직업 명성(prestige)은 양의 방향으로 유의미한 영향을 미침.
- 여성 비율은 음의 방향으로 유의미한 영향을 미침 → 직업에서 여성 비율이 높을수록 평균 수입은 낮은 경향.

```
> summary(mod1)

Call:
lm(formula = income ~ education + prestige + women, data = newdata)

Residuals:
    Min      1Q  Median      3Q     Max
-7715.3  -929.7  -231.2   689.7 14391.8

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) -253.850   1086.157  -0.234    0.816
education    177.199    187.632   0.944    0.347
prestige     141.435     29.910   4.729 7.58e-06 ***
women        -50.896      8.556  -5.948 4.19e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2575 on 98 degrees of freedom
Multiple R-squared:  0.6432,    Adjusted R-squared:  0.6323
F-statistic: 58.89 on 3 and 98 DF,  p-value: < 2.2e-16
```

① income을 설명하는 데 얼마나 중요한 변수인지를 나타냄

③ 모델이 income을 얼마나 잘 설명할 수 있는지를 나타냄

독립 변수들이 종속 변수의 변동성을 약 63.23% 설명.

② 구한 모델이 의미 있는 모델인지를 나타냄

적어도 하나 이상의 독립 변수가 종속 변수(income)에 유의미한 영향

그림 11-4 회귀모델에 대한 설명 내용

2. 다중선형 회귀모델에서 변수의 선택

- 다중선형 회귀모델에서는 종속변수를 설명하는 데 도움되는 독립변수가 다수 존재
- 그런데 모든 독립변수가 종속변수를 설명하는 데 동일하게 기여하는 것은 아님
- 어떤 변수는 기여도가 높고, 어떤 변수는 기여도가 낮음
- 예를 들어 '수면시간', '학습시간'은 '성적'을 예측하는 데 중요한 기여를 할 수 있지만, '점심식사 여부'는 '성적'을 예측하는 데 별로 도움이 되지 않는 변수
- 기여도가 낮거나 거의 없는 변수들은 모델에서 제외하는 것이 좋음(적은 변수를 가지고 현실을 잘 설명할 수 있는 것이 좋은 모델이기 때문)
- R에서는 모델에 기여하는 변수들을 선별할 수 있는 setpAIC() 함수를 제공
  - AIC (Akaike Information Criterion)
- stepAIC 함수의 목적
  - 각 단계에서 AIC 값이 가장 크게 감소하는 변수를 제거하면서 최적의 모형을 찾는 것
  - 단계가 올라갈수록 단계의 AIC는 작아짐

코드 11-5

```
library(MASS)                          # stepAIC( ) 함수 제공
newdata2 <- Prestige[,c(1:5)] # 모델 구축에 사용할 데이터셋 생성
head(newdata2)
mod2 <- lm(income ~ education + prestige +
           women + census, data= newdata2)
mod3 <- stepAIC(mod2)          # 변수 선택 진행
mod3                                   # 변수 선택 후 결과 확인
summary(mod3)                          # 회귀모델 상세 내용 확인
```

```
> library(MASS)                              # stepAIC( ) 함수 제공
> newdata2 <- Prestige[,c(1:5)]              # 모델 구축에 사용할 데이터셋 생성
> head(newdata2)
                    education income womenprestige census
gov.administrators      13.11  12351 11.16     68.8   1113
general.managers        12.26  25879  4.02     69.1   1130
accountants             12.77   9271 15.70     63.4   1171
purchasing.officers     11.42   8865  9.11     56.8   1175
chemists                14.62   8403 11.68     73.5   2111
physicists              15.64  11030  5.13     77.6   2113
> mod2 <- lm(income ~ education + prestige +
+            women + census, data= newdata2)>
```

2. 다중선형 회귀분석

```
> mod3 <- stepAIC(mod2)                    # 변수 선택 진행
Start:  AIC=1607.93
income ~ education + prestige + women + census

            Df  Sum of Sq       RSS    AIC
- census     1     639658 649654265 1606.0
- education  1    5558323 654572930 1606.8
<none>                   649014607 1607.9
- prestige   1  143207106 792221712 1626.3
- women      1  212639294 861653901 1634.8

Step:  AIC=1606.03
income ~ education + prestige + women

            Df  Sum of Sq       RSS    AIC
- education  1    5912400 655566665 1605.0
<none>                   649654265 1606.0
+ census     1     639658 649014607 1607.9
- prestige   1  148234959 797889223 1625.0
- women      1  234562232 884216497 1635.5

Step:  AIC=1604.96
```

-: 제거한가면
+: 추가한다면

현재, 해당 독립변수를 제거한 경우 예상되는 AIC 값이므로 결과가 가장 좋은 (값이 작은) 제일 상단인 cencus를 제거하는 것이 다음 단계

동일

1 단계에서 제거 대상:
AIC가 가장 작은 열

- ❖ AIC(Akaike Information Criterion, 아카이케 정보 기준)는 통계 모델의 "적절성"과 "간결성"을 동시에 평가하는 지표
- ❖ 숫자가 작을수록 좋은 모델이며, 과적합 없이 데이터를 잘 설명하는 모델을 고르는 데 사용
- ❖ AIC는 단순히 정확도만 보는 게 아니라, 모델이 얼마나 복잡한지까지 벌점을 준다는 점이 핵심

2 단계에서 제거 대상:
AIC가 가장 작은 열

2. 다중선형 회귀분석

```
income ~ prestige + women

           Df  Sum of Sq        RSS    AIC
<none>                     655566665 1605.0
+ education  1    5912400  649654265 1606.0
+ census     1     993735  654572930 1606.8
- women      1  234647032  890213697 1634.2
- prestige   1  811037947 1466604612 1685.1
> mod3                                  # 변수 선택 후 결과 확인

Call:
lm(formula = income ~ prestige + women, data = newdata2)

Coefficients:
(Intercept)     prestige        women
     431.57       165.87       -48.38
> summary(mod3)                         # 회귀모델 상세 내용 확인

Call:
```

현재 presige + women으로 AIC가 1605인데, women을 제거하면 1634.2, prestige를 제거하면 1685.1로 더 안 좋은 결과가 나오므로 여기서 종료

2. 다중선형 회귀분석

```
lm(formula = income ~ prestige + women, data = newdata2)

Residuals:
    Min      1Q  Median      3Q     Max
-7620.9 -1008.7  -240.4   873.1 14180.0

Coefficients:
            Estimate Std.Error t value  Pr(>|t|)
(Intercept) 431.574   807.630    0.534     0.594
prestige    165.875    14.988   11.067   < 2e-16   ***
women       -48.385     8.128   -5.953  4.02e-08   ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2573 on 99 degrees of freedom
Multiple R-squared:  0.64,Adjusted R-squared:  0.6327
F-statistic: 87.98 on 2 and 99 DF,  p-value: < 2.2e-16
```

어떤 독립변수를 제거할거냐?

지표인 AIC 값이 작아지도록

```
> mod3 <- stepAIC(mod2)                    # 변수 선
Start:  AIC=1607.9
income ~ education + prestige + women + census

            Df Sum of Sq      RSS  AIC
- census     1  6.40e+05 6.50e+08 1606
- education  1  5.56e+06 6.55e+08 1607
<none>                   6.49e+08 1608
- prestige   1  1.43e+08 7.92e+08 1626
- women      1  2.13e+08 8.62e+08 1635

Step:  AIC=1606
income ~ education + prestige + women

            Df Sum of Sq      RSS  AIC
- education  1  5.91e+06 6.56e+08 1605
<none>                   6.50e+08 1606
- prestige   1  1.48e+08 7.98e+08 1625
- women      1  2.35e+08 8.84e+08 1635

Step:  AIC=1605
income ~ prestige + women

            Df Sum of Sq      RSS  AIC
<none>                   6.56e+08 1605
- women      1  2.35e+08 8.90e+08 1634
- prestige   1  8.11e+08 1.47e+09 1685
```

- 목적: 변수 선택을 통한 모델 성능 향상
- stepAIC(mod3)는 AIC (Akaike Information Criterion) 값을 최소화하는 방향으로 변수 선택을 수행함.
- AIC는 모델의 예측력과 단순함의 균형을 평가하는 기준으로 값이 작을수록 좋음.
- backward 방식으로 시작 → 덜 유의미한 변수를 하나씩 제거하며 AIC 감소 여부 확인.

- ◈ Step 1: 시작점
- 시작 모델: income ~ education + prestige + women + census
- AIC = 1607.9
- census를 제거하면 AIC가 1606으로 감소 → 제거 결정

- ◈ Step 2: education 제거 시도
- 현재 모델: income ~ education + prestige + women
- AIC = 1606
- education 제거 시 AIC = 1605 → education도 제거함

- ◈ Step 3: 제거 완료
- 최종 모델: income ~ prestige + women
- AIC = 1605 → 이후 어느 변수도 제거 시 AIC 증가 → 종료

- ◈ - 선택된 변수
- prestige: 높은 명성일수록 수입 증가 → 강한 양(+)의 영향
- women: 여성 비율 높을수록 수입 감소 → 음(-)의 영향
- ◈ - 제거된 변수
- education: 수입에 통계적으로 유의하지 않았음 (앞선 summary()에서도 p-value = 0.35)
- census: 지역 코드 변수, 정보량 부족하거나 noise로 작용했을 가능성

Section 03

로지스틱 회귀분석

1. 로지스틱 회귀분석의 개념

- **로지스틱 회귀(logistic regression) :** 회귀모델에서 종속변수의 값의 형태가 연속형 숫자가 아닌 범주형 값인 경우를 다루기 위해서 만들어진 통계적 방법
  ex) iris 데이터셋에서 4개의 측정값을 가지고 품종을 예측. 품종이 범주형 값
- R에서 로지스틱 회귀 모델은 glm() 함수 이용
  - 일반화 선형 모델(Generalized Linear Model)

2. 로지스틱 회귀모델 만들기

코드 11-6

```
iris.new <- iris
iris.new$Species <- as.integer(iris.new$Species) # 범주형 자료를 정수로 변환
head(iris.new)
mod.iris <- glm(Species ~., data= iris.new)        # 로지스틱 회귀모델 도출
summary(mod.iris)                                  # 회귀모델의 상세 내용 확인
```

3. 로지스틱 회귀분석

```
> iris.new <- iris
> iris.new$Species <- as.integer(iris.new$Species)   # 범주형 자료를 정수로 변환
> head(iris.new)
  Sepal.Length Sepal.Width Petal.Length Petal.Width Species
1          5.1         3.5          1.4         0.2       1
2          4.9         3.0          1.4         0.2       1
3          4.7         3.2          1.3         0.2       1
4          4.6         3.1          1.5         0.2       1
5          5.0         3.6          1.4         0.2       1
6          5.4         3.9          1.7         0.4       1
> mod.iris <- glm(Species ~., data= iris.new)        # 로지스틱 회귀모델 도출
```

- **Species ~.**

  회귀모델에서 종속변수가 Species이고, 나머지 변수들은 모두 독립변수이다.

- **data=iris.new**

  회귀모델 도출에 사용할 데이터셋이 iris.new이다.

3. 로지스틱 회귀분석

- Species를 종속 변수로 하고, 나머지 모든 변수(.)를 독립 변수로 사용한 일반화 선형 모델

```
> mod.iris <- glm(Species ~ ., data = iris.new)     # 로지스틱 회귀모델 도출
> summary(mod.iris)                                 # 회귀모델의 상세 내용 확인

Call:
glm(formula = Species ~ ., data = iris.new)

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)   1.18650    0.20484   5.792 4.15e-08 ***
Sepal.Length -0.11191    0.05765  -1.941   0.0542 .
Sepal.Width  -0.04008    0.05969  -0.671   0.5030
Petal.Length  0.22865    0.05685   4.022 9.26e-05 ***
Petal.Width   0.60925    0.09446   6.450 1.56e-09 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for gaussian family taken to be 0.04800419)

    Null deviance: 100.0000  on 149  degrees of freedom
Residual deviance:   6.9606  on 145  degrees of freedom
AIC: -22.874

Number of Fisher Scoring iterations: 2
```

- Petal.Length와 Petal.Width는 Species를 예측하는 데 매우 유의미한 변수
- Sepal.Length는 10% 수준에서 유의(.), 경계선상
- Sepal.Width는 p-값이 0.5로 유의하지 않음 → 종 예측에 기여도가 낮음

- AIC가 매우 낮다는 것은 모델의 적합도는 좋다는 의미(선형 회귀 기준)

3. 로지스틱 회귀모델을 이용한 예측

- 수작업으로 계산하여 품종을 예측하는 방법 대신, 구해놓은 회귀모델을 이용하여 보다 편리한 방법으로 품종을 예측

코드 11-7

```
# 예측 대상 데이터 생성(데이터프레임)
unknown <- data.frame(rbind(c(5.1, 3.5, 1.4, 0.2)))
names(unknown) <- names(iris)[1:4]
unknown                                          # 예측 대상 데이터

pred <- predict(mod.iris, unknown)               # 품종 예측
pred                                             # 예측 결과 출력
round(pred,0)                  # 예측 결과 출력(소수 첫째 자리에서 반올림)

# 실제 품종명 알아보기
pred <- round(pred,0)
pred
levels(iris$Species)
levels(iris$Species)[pred]
```

3. 로지스틱 회귀분석

```
> # 예측 대상 데이터 생성(데이터프레임)
> unknown <- data.frame(rbind(c(5.1, 3.5, 1.4, 0.2)))
> names(unknown) <- names(iris)[1:4]
> unknown                                    # 예측 대상 데이터
  Sepal.Length Sepal.Width Petal.Length Petal.Width
1          5.1         3.5          1.4         0.2
pred <- predict(mod.iris, unknown)                  # 품종 예측
```

- **mod.iris**
  로지스틱 회귀모델을 의미한다.
- **unknown**
  예측 대상 데이터를 의미한다. 데이터 1건을 입력할 수도 있고 여러 개를 묶어서 입력할 수도 있다.

3. 로지스틱 회귀분석

```
> pred                                  # 예측 결과 출력
        1
0.9174506
> round(pred,0)                         # 예측 결과 출력(소수 첫째 자리에서 반올림)
1
1
> # 실제 품종명 알아보기
> pred <- round(pred,0)
> pred
1
1
> levels(iris$Species)
[1] "setosa"     "versicolor" "virginica"
> levels(iris$Species)[pred]
[1] "setosa"
```

4. 다수의 데이터에 대한 예측

- 예측 대상 데이터가 여러 개인 경우에도 유사한 방법으로 예측

코드 11-8

```
test <- iris[,1:4]                          # 예측 대상 데이터 준비
pred <- predict(mod.iris, test)             # 모델을 이용한 예측
pred <- round(pred,0)
pred                                        # 예측 결과 출력
answer <- as.integer(iris$Species)          # 실제 품종 정보
pred == answer                  # 예측 품종과 실제 품종이 같은지 비교
acc <- mean(pred == answer)                 # 예측 정확도 계산
acc                                         # 예측 정확도 출력
```

```
> test <- iris[,1:4]                        # 예측 대상 데이터 준비

> pred <- predict(mod.iris, test)           # 모델을 이용한 예측
```

```
> pred <- round(pred,0)
> pred                                          # 예측 결과 출력
  1   2   3   4   5   6   7   8   9  10  11  12  13  14  15  16  17
  1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1
 18  19  20  21  22  23  24  25  26  27  28  29  30  31  32  33  34
  1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1
 35  36  37  38  39  40  41  42  43  44  45  46  47  48  49  50  51
  1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   1   2
... (중간 생략)
103 104 105 106 107 108 109 110 111 112 113 114 115 116 117 118 119
  3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3   3
120 121 122 123 124 125 126 127 128 129 130 131 132 133 134 135 136
  2   3   3   3   3   3   3   3   3   3   3   3   3   3   2   3   3
137 138 139 140 141 142 143 144 145 146 147 148 149 150
  3   3   3   3   3   3   3   3   3   3   3   3   3   3
```

3. 로지스틱 회귀분석

```
> answer <- as.integer(iris$Species)        # 실제 품종 정보
> pred == answer                            # 예측 품종과 실제 품종이 같은지 비교
    1     2     3     4     5     6     7     8     9    10    11
 TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
   12    13    14    15    16    17    18    19    20    21    22
 TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
   23    24    25    26    27    28    29    30    31    32    33
 TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
... (중간 생략)
  122   123   124   125   126   127   128   129   130   131   132
 TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
  133   134   135   136   137   138   139   140   141   142   143
 TRUE FALSE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
  144   145   146   147   148   149   150
 TRUE  TRUE  TRUE  TRUE  TRUE  TRUE  TRUE
> acc <- mean(pred == answer)               # 예측 정확도 계산
> acc                                       # 예측 정확도 출력
[1] 0.9733333
```

Thank you!

한빛아카데미 Hanbit Academy, Inc.